

Wprowadzenie

Rynek gier komputerowych jest rozwijającą się branżą, generującą rosnącą ilość danych tekstowych w postaci recenzji, często charakteryzujących się dużym zróżnicowaniem, kontrowersyjnością, nierzadko specyficznym slangiem. Analiza takich danych może być niezwykle przydatna do identyfikacji obszarów doskonalenia produktów oraz zrozumienia doświadczeń graczy.

Jednakże, z uwagi na rosnący wolumen danych, ta analiza staje się trudna logistycznie. W tym celu niezwykle pomocne stają się systemy przetwarzające dane i przeprowadzające ich ewaluację pod względem słownictwa.

Celem projektu jest opracowanie systemu do eksploracji danych tekstowych w postaci recenzji gry "007 First Light" opublikowanych na platformie Steam. Program zaimplementowany w R Studio wykorzystuje metody badania tekstu takie jak analiza częstości słów, czy TF-IDF, które umożliwiają identyfikację słów kluczowych w badanych danych z pliku CSV.

Projekt został przygotowany zgodnie z ideą Reproducible Research - użytkownik jest w stanie odtworzyć cały proces analityczny przy użyciu tych samych danych i kodu, otrzymując każdorazowo te same wyniki.

Cele systemu

- Automatyczne przetwarzanie opinii tekstowych pochodzących z platformy Steam.
- Identyfikacja najważniejszych słów w zbiorze danych (na podstawie częstości wystąpienia i wag wyliczonych metodą TF-IDF).
- Wizualizacja wyników w postaci tabel i chmury słów.
- Wspomaganie analizy opinii graczy poprzez wyróżnienie słów kluczowych, istotnych tematów.
- Dostarczenie informacji pomocnych w krytycznej ocenie produktu i wsparciu jego ewentualnego dopracowania poprzez identyfikację obszarów doskonalenia.

Wymagania funkcjonalne

- System umożliwia wczytanie danych z pliku CSV zawierającego opinie tekstowe.
- System ma przetwarzać i oczyszczać tekst pochodzący ze wczytanych dokumentów, m.in. zmieniać wszystkie litery na małe, usuwać zbędne symbole, słowa (stop words i inne), znaki interpunkcyjne, adresy URL.
- System będzie tworzyć macierz TDM z wagami TF-IDF dla słów ze wczytanych dokumentów, sortując je.
- System ma zliczać częstość występowania słów w dokumentach.
- System utworzy tabele, przyporządkowujące słowom wagi i częstość wystąpienia.
- System wygeneruje chmurę słów na podstawie wyliczonych parametrów- prezentacja wyników analizy.
- System powinien wygenerować raport HTML z wynikami kodu.

Wymagania нефункционалне

- Код повинен діяти правильно, містити зчителні і щогółові коментарі в цілу улаівненія його зчителносії і уможливленія евенуалньох модифікацій.
- Систем повинен вчитати файл містять до 10000 опіній в часі неперекрацаючым 10 секунд.
- Процес творенія матриці TDM oraz облічання ваг TF-IDF повинен діяти в часі крóтшым ніж 60 секунд для збіору 10000 опіній.
- Систем повинен перепровадзати аналіз правильно при за́ложенію одповіднього приготування даних wejściowych.
- Wyniki analizy повинні б́іть представілені в спосóб зчителнь.
- Систем повинен діяти правильно в RStudio при за́ложенію вчэньнейсей інсталяції вимаганих паке́тów.
- Повторне уручомленіе коду на тих самых даних повинно за́всегдэ дава́ць то́жсаме wyniki.

Interfejsy użytkownika

- Wejście:
 - Plik w formacie .csv містять опінії клієнтów
 - Parametry analizy модифіковальне безпосредніо в скріпті R (min.freq, max.words, ścieżka do pliku)
- Wyjście:
 - Chmura słów (wordcloud) wygenerowana na podstawie ваг TF-IDF
 - Tabelka z 10 słowami o najwyższej wadze TF-IDF
 - Raport HTML wygenerowany ze skryptu R

Wymagania dotyczące danych

- Skrypt zakłada, że dane tekstowe są w języku angielskim.
- Skrypt nie obsługuje analizy dla innych języków niż angielski.
- Skrypt wykorzystuje listę stopwords z pakietu tm w wersji angielskiej.
- Skrypt nie obsługuje analizy dla danych tekstowych z innych źródeł niż pliki .csv.
- Wymagana kolumna tekstowa w pliku .csv to Review.text..Original.

Słownictwo dokumentacji

- TF-IDF (Term Frequency - Inverse Document Frequency): statystyczna metoda obliczania wagi słowa w jednym dokumencie na tle całego zbioru dokumentów
- TDM (Term-Document Matrix): macierz, w której wiersze są reprezentacją słów, a kolumny dokumentów, natomiast jej wartości to wagi TF-IDF danego słowa w danym dokumencie
- Token: pojedynczy element tekstu (słowo)

- Korpus: zbiór dokumentów tekstowych przetwarzanych przez skrypt
- Stopwords: słowa, które z punktu widzenia analizy nie mają znaczenia w dokumencie
- Chmura słów (wordcloud): wizualizacja pozwalająca zobaczyć najważniejsze i najczęściej występujące słowa w tekście dzięki dostosowaniu wielkości czcionki do wagi danego słowa
- Stemming: redukcja słów do ich rdzenia

Przypadki użycia (use cases)

- Użytkownik:
 - wczytuje plik .csv z opiniami klientów
 - uruchamia analizę w skrypcie R
 - wyświetla wyniki w postaci chmury słów i tabelki
 - generuje raport html
- Skrypt/system:
 - wczytuje dane z pliku .csv i tworzy korpus dokumentów
 - oczyszcza tekst (zmienia litery na małe, usuwa cyfry, znaki specjalne, znaki interpunkcyjne, stopwords oraz nadmiarowe spacje)
 - buduje macierz TDM z wagami TF-IDF
 - generuje chmurę słów na podstawie wag TF-IDF
 - generuje tabelę 10 słów o najwyższej wadze
 - generuje raport HTML z wynikami
- Testowe przypadki użycia
 - Test z plikiem .csv zawierającym opinie o pozytywnym wydźwięku.
 - Test z plikiem .csv zawierającym opinie o negatywnym wydźwięku.
 - Test z plikiem .csv zawierającym opinie o neutralnym wydźwięku.
 - Test z plikiem .csv zawierającym opinie o mieszanym wydźwięku.
 - Test z plikiem .csv zawierającym brakujące wartości.
 - Test z plikiem .csv zawierającym znaki specjalne i emotikony.

Scenariusze użytkownika (user stories)

Scenariusz 1: Analiza opinii klientów o grze

- Jako: Analityk marketingowy
- Chcę: Przeanalizować opinie klientów (zapisane w pliku .csv) o nowej grze
- Aby: Zidentyfikować słowa kluczowe najsilniej charakteryzujące zbiór opinii i wyciągnąć wnioski dotyczące postrzegania gry.

Kryteria akceptacji:

- Użytkownik może wczytać plik .csv z opiniami klientów.
- Skrypt przeprowadza pełne czyszczenie tekstu i buduje macierz TF-IDF.
- Skrypt generuje chmurę słów oraz tabelkę najważniejszych słów.
- Użytkownik otrzymuje raport HTML.
- Użytkownik może zidentyfikować najważniejsze kwestie poruszane przez klientów w opiniach i dzięki temu obszary, które mogą wymagać poprawy.

Scenariusz 2: Porównanie zbiorów opinii

- Jako: Analityk danych
- Chcę: Uruchomić analizę na różnych plikach .csv (np. opinie z różnych okresów lub różnych źródeł)
- Aby: Porównać, które słowa kluczowe dominują w poszczególnych zbiorach.

Kryteria akceptacji:

- Użytkownik może wczytać plik .csv z opiniami klientów, a następnie podmienić ścieżkę do tego pliku w skrypcie (by wykonać kod dla kolejnego zbioru danych) bez modyfikowania pozostałej części kodu.
- Skrypt generuje spójne wyniki dla różnych zbiorów danych spełniających wymagania formatu.
- Użytkownik może porównać wygenerowane raporty HTML między sobą.

Scenariusz 3: Sprawdzenie czy gra jest warta zakupu

- Jako: Gamer
- Chcę: Pobrać kod repozytorium GitHub i uruchomić analizę na własnym komputerze.
- Aby: Przeanalizować wyniki analizy i zobaczyć jakie wady/zalety gry pojawiają się najczęściej w opiniach innych graczy by zdecydować czy warto ją nabyć.

Kryteria akceptacji:

- Repozytorium zawiera kod źródłowy R.
- Po zainstalowaniu wymaganych pakietów i zmodyfikowaniu ścieżki do danych skrypt uruchamia się bez dalszych modyfikacji.
- Wyniki są łatwe do interpretacji dzięki wizualnej reprezentacji w postaci chmury słów.